

F1 Tyre Analysis: Integrazione di Conoscenza di Dominio per la Stima del Degrado Pneumatici in Formula 1

Un approccio statistico-predittivo per il supporto decisionale

Matteo Miglio

Università degli Studi di Trento

Student ID: 243947

Esame: Introduzione all'Intelligenza Artificiale [120479]

matteo.miglio@studenti.unitn.it

<https://github.com/Magnus3327/F1-Tyre-Analysis>

Abstract

L'ottimizzazione delle strategie di gara in Formula 1 dipende in larga misura dalla corretta stima del degrado degli pneumatici. Questo report presenta una metodologia strutturata, basata sull'integrazione di conoscenza di dominio (Domain Knowledge Integration), per isolare ed analizzare il puro degrado fisico degli pneumatici in Formula 1 utilizzando dati telemetrici reali forniti dalle API di FastF1. Affrontando il classico problema econometrico della multicollinearità, il modello opera una correzione a priori fondata su principi fisici e utilizza una regressione robusta (Huber Regressor) per filtrare la varianza stocastica e gli shock esogeni. I risultati dimostrano come l'algoritmo, validato tramite Mean Absolute Error (MAE), sia in grado di estrarre un tasso di degrado fisicamente coerente, fornendo metriche di supporto alle decisioni tattiche al netto di ipotesi semplificative sulle variabili ambientali.

1 Introduzione: Problema e Motivazione

In contesti ad alta competitività come la Formula 1, i dati telemetrici rappresentano un asset fondamentale per ottenere un vantaggio competitivo. Una delle sfide decisionali più complesse per gli ingegneri strategici è determinare il momento ottimale per il pit-stop, una scelta guidata quasi interamente dal livello di degrado degli pneumatici (Milliken and Milliken, 1995).

Il **problema di ricerca** affrontato in questo elaborato consiste nell'isolare il puro degrado fisico della mescola dall'effetto di variabili confondenti e dal rumore esterno (traffico, bloccaggi, doppiaggi) utilizzando dati reali.

La **motivazione** alla base di questo studio è la necessità di superare i limiti delle misurazioni empiriche dirette. In gara, non è possibile misurare fisicamente lo spessore del battistrada; il degrado deve essere inferito dall'aumento dei tempi sul giro.

Tuttavia, il tempo sul giro è una metrica soggetta a forte rumore, influenzata da molteplici fattori simultanei. Sviluppare un modello in grado di depurare questa variabile permette di ottimizzare l'allocazione delle risorse (scelta delle mescole) e fornire ai decisori metriche oggettive per la strategia di gara.

2 Architettura e Data Ingestion

Il progetto è strutturato come una pipeline software modulare scritta interamente in Python, progettata secondo i principi di riproducibilità e modularità dell'ingegneria del software. L'architettura prevede i seguenti blocchi funzionali:

- **Data Collection** (`dataCollector.py`): Interfaccia con l'API open-source FastF1 (Oehrly, 2021). Scarica i dati relativi ai giri di gara per anno, Gran Premio e pilota specificati. Viene implementato un sistema di caching locale persistente per ridurre il sovraccarico delle API.
- **Preprocessing** e **Pulizia** (`preprocessing.py`): Pulisce la telemetria grezza rimuovendo le sessioni anomale. Filtra i giri effettuati sotto bandiera gialle o Safety Car sfruttando lo stato della pista (`TrackStatus`), esclude i tempi di entrata e uscita dai box (`PitInTime/PitOutTime`) e rimuove i primi due giri di assestamento termico di ogni treno di gomme (`TyreLife > 2`).
- **Model Training** (`modelTraining.py`): Implementa la logica di correzione del peso del carburante e addestra il modello di regressione robusta per stimare il tasso di degrado.
- **Plotting** (`plotter.py`): Genera output grafici di qualità scientifica utilizzando la libreria `matplotlib` per documentare visivamente il fitting e il confronto tra le mescole.

- **Analysis** (`analysis.py`): Fornisce aggregazioni statistiche e stampe tabellari dei risultati per l'interpretazione strategica.

3 Il Problema della Multicollinearità e Integrazione di Conoscenza a Priori

La sfida statistica principale nell'addestramento di un modello predittivo sui tempi sul giro è la presenza di una *forte multicollinearità* tra due variabili chiave durante un singolo stint di gara:

1. **Consumo di carburante:** il peso della vettura diminuisce linearmente, portando a un abbassamento dei tempi sul giro.
2. **Usura della gomma:** la performance dello pneumatico peggiora progressivamente, portando a un innalzamento dei tempi sul giro.

L'applicazione di algoritmi classici di Machine Learning (come Ordinary Least Squares OLS o Ridge) su questi dati grezzi tende a produrre coefficienti instabili o fisicamente incoerenti. L'algoritmo non è in grado di discriminare tra l'effetto positivo dell'alleggerimento e l'effetto negativo dell'usura, portando spesso all'assegnazione di coefficienti distorti che generano tassi di degrado negativi (fisicamente impossibili).

Per risolvere questa multicollinearità, si combina la *Domain Knowledge* con algoritmi di ottimizzazione robusta, applicando una correzione empirica a priori. È noto nel dominio della Formula 1 che una vettura perde circa 0.03 secondi per ogni chilogrammo di carburante a bordo (0.03 s/kg), dovuta sia alla maggiore inerzia sia al lavoro supplementare richiesto agli pneumatici.

Prima dell'addestramento, i tempi sul giro sono stati corretti sottraendo il vantaggio prestazionale derivante dal carburante bruciato:

$$Y_{corrected}(t) = Y_{raw}(t) - (M_{fuel}(t) \cdot 0.03 \text{ s/kg}) \quad (1)$$

In questo modo, al modello di Machine Learning viene fornita una variabile dipendente ($Y_{corrected}$) che riflette esclusivamente il decadimento prestazionale dovuto alla variabile indipendente (*TyreLife* e il suo termine quadratico $TyreLife^2$ per il crollo prestazionale).

4 Il Modello: Regressione Robusta e Validazione Dinamica

I dati telemetrici sono soggetti a forte non-stazionarietà e shock esogeni. Per evitare che i

cosiddetti *outlier* (es. un errore di guida che causa un giro insolitamente lento) distorcano la curva di tendenza, il modello implementa una **Huber Regressor** (Huber, 1964).

A differenza della classica funzione di costo quadratica (MSE), la Huber Loss adotta un approccio ibrido:

$$L_{\delta}(a) = \begin{cases} \frac{1}{2}a^2 & \text{se } |a| \leq \delta \\ \delta(|a| - \frac{1}{2}\delta) & \text{altrimenti} \end{cases} \quad (2)$$

Questa formulazione è quadratica per i piccoli errori e lineare per i grandi, permettendo al modello di ignorare matematicamente i giri anomali causati dal traffico e tracciare la vera parabola di usura.

Modelliamo l'usura tramite un'equazione quadratica per catturare l'andamento non-lineare tipico delle mescole a fine vita:

$$Y_{corrected} = w_0 + w_1 \cdot TyreLife + w_2 \cdot TyreLife^2 \quad (3)$$

Il tasso di degrado istantaneo medio dello stint viene calcolato valutando la derivata prima della curva quadratica rispetto alla vita media dello pneumatico $\bar{L}$:

$$Degradation = w_1 + 2 \cdot w_2 \cdot \bar{L} \quad (4)$$

Per garantire la robustezza statistica dei risultati, il modello adotta una **Cross-Validation K-Fold dinamica** integrata con lo shuffling casuale dei dati. Il numero di partizioni (fold) viene calcolato proporzionalmente alla lunghezza effettiva dello stint:

$$k = \max \left(2, \min \left(8, \frac{\text{Lunghezza Stint}}{5} \right) \right) \quad (5)$$

4.1 Il fallimento dell' R^2 su dati stocastici

Inizialmente, il modello è stato validato utilizzando il coefficiente di determinazione (R^2). Tuttavia, l'applicazione di una K-Fold Cross-Validation Dinamica ha restituito valori di R^2 fortemente negativi. Questa anomalia metrica deriva dal paradosso di combinare un modello robusto agli outlier (Huber) con una metrica di valutazione basata sull'errore quadratico (R^2). Se il set di validazione contiene un singolo giro influenzato da traffico pesante (es. +3 secondi), il modello predice correttamente il tempo "pulito", ma la metrica R^2 eleva l'errore al quadrato, penalizzando ingiustamente l'algoritmo. Si è pertanto optato per il **Mean Absolute Error (MAE)**, che offre una valutazione lineare e un'eccellente interpretabilità (esprimendo l'errore medio in secondi a giro).





Figure 1: Analisi di regressione robusta per lo Stint 1 (Medium, sinistra) e lo Stint 2 (Hard, destra) di Charles Leclerc nel GP di Monza 2023. Le crocette rosse indicano gli outlier identificati ed esclusi dalla Huber loss.

4.2 Collinearità e Feature Selection

I tentativi iniziali di includere variabili ambientali nel modello hanno evidenziato un severo problema di *Confounding Effect*. La contemporanea discesa delle temperature serali e l'aumento dei giri percorsi mandava l'algoritmo in totale confusione, portandolo a stimare tassi di degrado irrealistici (fino a 0.25 s/lap per mescole Hard). Rimuovendo la variabile ambientale e operando una stretta *Feature Selection* sull'usura pura, l'errore MAE è crollato in maniera significativa e il tasso di degrado si è stabilizzato su valori fisicamente coerenti con il comportamento delle mescole Pirelli, dimostrando che i modelli più parsimoniosi garantiscono una maggiore capacità di generalizzazione sui singoli stint.

5 Evidenze Emerse ed Analisi

Abbiamo testato la pipeline di modellazione analizzando la gara di **Charles Leclerc** nel **Gran Premio d'Italia (Monza) 2023** su un totale di 51 giri percorsi. La gara ha previsto una strategia a singola sosta, suddivisa in due stint principali:

- **Stint 1 (Giri 1-21):** Gomma Medium, 17 giri validi estratti.
- **Stint 2 (Giri 22-51):** Gomma Hard, 29 giri validi estratti.

I grafici di regressione robusta per i singoli stint sono riportati in Figura 1. I risultati numerici estratti dal modello sono riassunti in Tabella 1.

Dall'analisi delle figure e delle tabelle emergono tre evidenze cruciali:

1. **Isolamento degli Outlier:** Nei grafici di Figura 1, le crocette rosse mostrano come

Stint	Mescola	Degrado (s/lap)	MAE (s)
1	MEDIUM	0.159	0.227
2	HARD	0.092	0.279

Table 1: Risultati dettagliati dell'analisi di degrado per Charles Leclerc (Monza 2023).




Figure 2: Confronto globale del tasso di degrado medio estratto per lo stint su Medium e su Hard, normalizzato rispetto all'effetto benzina.

l'algoritmo basato sulla Huber Loss abbia identificato ed escluso con precisione i giri affetti da traffico e doppiaggi (giri fino a 1.5 secondi più lenti rispetto al trend ideale). La curva arancione di Trend ML rappresenta l'effettiva usura fisica senza distorsioni.

2. **Coerenza Fisica delle Mescole:** Il modello ha calcolato un tasso di degrado pari a **0.159 s/giro** per la mescola Medium e **0.092 s/giro** per la mescola Hard (Figura 2). Questo rispecchia fedelmente la gerarchia reale degli pneumatici Pirelli: la mescola più morbida (Medium) garantisce

maggior prestazione iniziale ma degrada molto più velocemente rispetto alla miscela più dura (Hard).

3. Risoluzione delle Collinearità Inverse:

Prima dell'intervento di *Feature Selection* e della rimozione della variabile ambientale (temperatura), i modelli distorti dalla multicollinearità arrivavano a invertire erroneamente questa gerarchia, assegnando degradi irrealistici alle mescole dure. Il corretto allineamento dei risultati attuali con le aspettative ingegneristiche rappresenta una forte evidenza empirica dell'efficacia dell'approccio proposto nel filtrare i bias stocastici.

6 Limitazioni e Sviluppi Futuri

Nonostante l'eccellente accuratezza, il modello presenta alcune limitazioni fisiche semplificative:

- **Dinamizzazione della Costante del Carburante:** L'attuale penalità fissa di 0.03 s/kg è un'approssimazione empirica ottimale per circuiti veloci come Monza, ma pecca di rigidità. Circuiti con layout differenti (es. ad alto carico aerodinamico come Monaco o Singapore) presentano sensibilità al peso molto diverse. Un miglioramento futuro di rilievo consiste nel rendere questa costante dinamica per ogni tracciato, correlandola alle caratteristiche geometriche della pista (numero di frenate, pendenza, velocità media) e, soprattutto, allineandola alle imminenti evoluzioni regolamentari.

Nel **regolamento tecnico 2026**, ad esempio, l'erogazione della potenza sarà ripartita al 50% tra il motore a combustione interna (ICE) e la componente elettrica (ERS). Questa massiccia elettrificazione sposterà l'efficienza energetica verso una gestione complessa del recupero energetico (*harvesting*) e del *clipping* (taglio di potenza elettrica nei rettilinei). Di conseguenza, il consumo di carburante e la gestione dei pesi saranno legati in modo non-lineare alla strategia di scaricamento della batteria per ogni singola pista. Integrare un modello dinamico di consumo carburante legato alla ripartizione di potenza elettrica/termica consentirà di ottenere stime di usura dello pneumatico estremamente più plausibili e conformi alla futura era della Formula 1.

- **Track Evolution e Meteo:** L'evoluzione del grip dell'asfalto e le variazioni di temperatura non sono attualmente modellate e potrebbero essere integrate come feature aggiuntive nel regressore.

- **Aria Sporca:** L'effetto scia e la perdita di carico aerodinamico quando si segue una vettura a meno di un secondo non vengono attualmente isolati.

7 Uso di GenAI (GenAI Disclosure)

In conformità con le linee guida dell'Università di Trento e le best practice di trasparenza accademica sull'uso dell'IA generativa, si dichiara che durante lo sviluppo di questo progetto è stato utilizzato un modello di IA (nello specifico, l'assistente virtuale *Antigravity* basato su *Google Gemini 3 Flash*) come strumento di supporto alla produttività e alla revisione.

Si precisa esplicitamente che tutti i testi di questo elaborato sono stati ideati, strutturati e concepiti interamente dall'autore. L'Intelligenza Artificiale è stata impiegata esclusivamente per il supporto nell'impaginazione del codice $\text{\LaTeX}$ e nella revisione dei contenuti al fine di migliorarne l'efficacia descrittiva, la sintassi e la correttezza della lingua italiana.

L'impiego dell'IA si è articolato specificamente nelle seguenti fasi:

- **Supporto allo Sviluppo e Debugging del Codice:** Assistenza nella risoluzione di errori di sintassi o disallineamento dei parametri (es. durante l'implementazione del plotter grafico) e suggerimenti sull'uso di specifiche funzioni delle librerie (come l'estrazione della maschera degli outlier in *scikit-learn*).
- **Impaginazione e Revisione Linguistica:** Supporto nell'impaginazione del codice $\text{\LaTeX}$ e nella revisione dei testi (concepiti dall'autore) per migliorarne la fluidità sintattica, la resa lessicale in italiano e l'efficacia descrittiva complessiva delle sezioni metodologiche.

8 Conclusioni

Il progetto dimostra l'efficacia dell'integrazione tra conoscenza empirica di dominio e modelli statistici robusti per estrarre segnale dal rumore. L'applicazione di correzioni a priori e un'accurata

selezione delle feature (al netto di alcune ipotesi semplificative sull'invarianza delle condizioni della pista) hanno mitigato il problema della multicollinearità, rendendo l'algoritmo stabile e interpretabile a supporto delle logiche decisionali strategiche.

References

Peter J. Huber. 1964. Robust estimation of a location parameter. *The Annals of Mathematical Statistics*, 35(1):73–101.

William F. Milliken and Douglas L. Milliken. 1995. *Race Car Vehicle Dynamics*. Society of Automotive Engineers Warrendale.

Theo Oehrly. 2021. Fastf1: A python package for accessing f1 historical data and telemetry. <https://github.com/theoehrly/Fast-F1>.

A Istruzioni per l'Esecuzione del Codice

Il codice è progettato per essere interamente eseguito tramite riga di comando (CLI). Per riprodurre l'analisi descritta in questo report, seguire i seguenti passaggi:

1. Installare le dipendenze necessarie specificate nel file `requirements.txt`:

```
pip install -r requirements.txt
```

2. Avviare l'analisi specificando i parametri desiderati (anno, Gran Premio e sigla pilota):

```
python src/main.py --year 2023
--gp Monza
--driver LEC
```

3. I risultati verranno stampati a console e i grafici verranno salvati automaticamente nella cartella `plots/2023_Monza_LEC/`.